Church Meeting Assistant: як працюють застосунок, сервер і M1

Стан на 13 вересня 2026. Опис того, що запущено, а не задуму з плану.

1. Три площини

Де	Що там стоїть	Що робить
Телефон або ноутбук служителя	браузер	відкриває `cma.rechurch.org.ua`: читає протоколи і стенограми, вантажить запис, ставить питання
VPS у Hetzner	FastAPI, Postgres, Qdrant, Caddy з TLS, теки зустрічей на диску	працює цілодобово, тримає весь стан; жодної моделі, 8 ГБ пам'яті
M1 (ноутбук удома)	Ollama з Gemma і bge-m3, Whisper, pyannote, реранкер, два воркери	усе, що потребує моделі: обробка запису і відповіді на питання

VPS і M1 з'єднані тунелем WireGuard. Postgres і Qdrant на VPS слухають лише адресу тунелю, ззовні їх не видно. M1 ходить до них як клієнт, а теки зустрічей копіює через rsync по SSH. Це роз'їзд від 24.08.2026. До нього все стояло на M1 в одній ролі `CMA_ROLE=all`, і цей режим досі є в скрипті запуску.

> **Про слово «застосунок».** Мобільного застосунку ще немає. Екрани, які показувались у демо, це макети зі статичної сторінки. Реальний клієнт сьогодні один: веб у браузері телефону або ноутбука. Telegram-бота прибрано 07.09, бо він відповідав на питання, які сервер мусив читати.



Ініціатива завжди від M1: VPS до ноутбука не звертається, воркери самі опитують черги.

2. Шлях запису до протоколу

Це робота ingestion-воркера на M1. Черга живе в таблиці `ingestion_jobs` на VPS. Воркер бере з неї задачі всіх церков разом, а церкву читає з самого рядка: від неї залежать тека, бібліотека голосових профілів і колекції в Qdrant.

1. **Завантаження.** Служитель вантажить аудіо через форму на вебі. Файл лягає в теку зустрічі на диску VPS, у базі з'являється джоб зі статусом `pending`.
2. **Pull на M1.** Воркер бачить джоб, переводить його в `transcribing` і тягне теку до себе разом із голосовими профілями церкви. Тут через тунель їде саме аудіо, близько 68 МБ на зустріч.
3. **Діаризація і транскрипція.** pyannote розділяє голоси і зіставляє їх із профілями, Whisper робить стенограму. Ollama тут не потрібна, тому ця фаза йде навіть коли Gemma лежить. На M1 це найдовша частина: години на одну зустріч.
4. **Push і пауза.** Воркер віддає стенограму і список спікерів на VPS, джоб стає `awaiting_review`. Ведучий на вебі перевіряє імена і додає тих, кого діаризація не почула. Це єдине місце, де людина в конвеєрі обов'язкова.
5. **Друга фаза.** Після підтвердження джоб стає `queued_analysis`. M1 знову тягне теку, зливає стенограму зі спікерами, Gemma аналізує її шматками і вигладжує протокол.
6. **Індексація.** bge-m3 на M1 рахує ембединги і кладе їх у Qdrant на VPS у колекції цієї церкви. Джоб стає `completed`, протокол їде на VPS.
7. **Читання.** Далі веб на VPS усе віддає сам: стенограму, протокол, теми, PDF. M1 у цьому вже не бере участі.

Кожен pull і push сидить усередині того самого `try`, що й стадія. Обрив тунелю посеред копіювання валить джоб у ретрай, а не лишає напівзаписану теку. Мережевий маунт пробували першим і відкинули: три години транскрипції задовгий час тримати NFS через тунель.

3. Шлях питання до відповіді

Це другий воркер, окремий від першого. Вони читають різні черги і працюють поруч.

1. Служитель пише питання у формі пошуку на вебі. Веб нічого не рахує: він кладе рядок у таблицю `queries` зі статусом `pending` і показує сторінку очікування.
2. Query-воркер на M1 опитує чергу через тунель. Раз на хвилину він також пише health-знімок у базу: чи живі Ollama і Qdrant. Саме цей знімок веб показує як «Обробник (M1): на зв'язку».
3. Воркер бере запит, ембедить його bge-m3, шукає в Qdrant на VPS, реранкує локально, і Gemma збирає відповідь. Усі моделі на M1; до VPS ходять лише вектори і знайдені пасажі.
4. Відповідь, знайдені пасажі і таймінги пишуться назад у той самий рядок. Веб перечитує його і показує результат.

> **Наслідок, який треба пам'ятати.** Коли M1 спить, черги просто ростуть. Веб живий, читати можна, а відповідей і нових протоколів немає, доки ноутбук не прокинеться. Воркер до 10.09 ще й гинув від першого розриву тунелю: так дев'ять днів провисів один запит. Виправлено: тепер він чекає і пробує знову.

4. Де зараз ключі і що бачить кожна машина

Код є

- Поля протоколу (присутні, кворум, питання, постанови, відповідальні) шифруються в репозиторії ключем церкви. Відкритими лишаються номери, дати, статуси і голоси.
- Теки зустрічей шифруються на межі синхронізації: на M1 плейнтекст, на VPS лише файли `.enc`, включно з аудіо.
- Ключ обробки лежить на M1 у `CMA_PROCESSOR_KEY`. Веб для зашифрованої церкви чесно каже «відкрийте в застосунку».

Продакшн навмисно позаду

- Усі церкви на VPS сидять на `kek_version = 0`, тобто плейнтекстом, як і до 07.09.
- Шифрування вмикається окремою командою на конкретну церкву. Поки що його ніхто не вмикав.
- Застосунку, який тримає ключ церкви, ще немає. Без нього для зашифрованої церкви веб напівсліпий, і читати протоколи ніде. Вмикати раніше за застосунок означало б зламати єдиний наявний клієнт.

Режим	VPS	M1	Клієнт
Сьогодні (роз'їзд, без шифрування)	бачить усе	бачить усе	браузер, ключа не має
Після ввімкнення шифрування	лише шифротекст і метадані: церква, дати, кількості, імена користувачів	плейнтекст під час обробки, потім видаляє	застосунок тримає ключ, розшифровує в себе
Self-host (`CMA_ROLE=all`)	відсутній	одна машина в церкві робить усе	браузер або застосунок у локальній мережі

Одна річ не змінюється в жодному режимі: машина, яка робить діаризацію і аналіз, чує запис і читає стенограму у відкритому вигляді. Обробки над шифротекстом не буває. Тому чесне питання до церкви не «чи витікає», а «чия машина слухає». Self-host відповідає «церкви»; хмарний режим відповідає «наша, і після обробки в нас лишається лише шифротекст».

5. Що потрібно для self-host

- Одна машина, яка тягне Whisper, pyannote і Gemma одночасно: рівня Mac mini з Apple Silicon або ПК з відеокартою. Дешевий VPS на 8 ГБ не підходить, він у нас саме тому і не рахує.
- Postgres і Qdrant у Docker, Ollama з моделями, Python-сервіси. Усе, що сьогодні розкладено на дві машини, збирається на одній роллю `CMA_ROLE=all`.
- Установлення сьогодні ручне, за інструкцією. Пакета «скачав і запустив» ще немає.
- Підтримка лягає на церкву: оновлення, бекапи, апдейти системи. Для церкви зі своїм айтішником це нормально; для церкви без нього лишається хмарний режим із шифротекстом.

Джерела: docs/cloud_plan.md §2, §3, §3.1, §5.0; docs/vps_deploy.md §0, §7, §9; deploy/env/*.env.example; src/church_assistant/ingestion, worker, shared/field_crypto.py. Репозиторій: github.com/kupolua/church-meeting-assistant.